






NEW TAIPEI HACK

留得青山在




新北糾察隊 - 青年局 AI 資料整合




系統架構 & 資料處理圖

- 系統架構介紹
- Data Pipeline



整體系統架構



Data Pipeline：自動化和更新即時性

Collectors → API Calling & 下載 Raw Data 保存原始資料

- JSON API：用 HTTP GET 呼叫 API，依月份 / 年度 / 行政區查詢
- PDF 檔：透過腳本爬蟲 & 解析資料 → 回傳JSON
- CSV：下載 CSV → 解析欄位與資料列
- TDX JSON API：使用 API Key & Token 呼叫 TDX REST API

Transform → 統一欄位 & 轉換格式

Loaders → 寫入資料庫、Backend

Analytics → 套用公式，計算相關數值及資料

整體系統架構




TABLE OF CONTENT

技術及工程架構

- 整體系統架構
- 三線處理邏輯

商業價值及分析

- 前端系統設計
- 特殊功能

GEN AI Performance & AWS 部署

- 圖譜消融試驗評分
- AWS 架構設計圖

技術及工程架構


- 整體系統架構
- 三線處理邏輯



整體系統架構




Offline



Artifact-first

整體系統架構



Online

API Input: query、location_code、duty_code

Query Normalization, Spell Check

Query Tagging

Intent Judging

Query Expansion

Hybrid Candidate Recall


Candidate Fusion

Cross-Encoder Reranker

Feature Table


Learning-to-Rank

三線處理邏輯



兩階二元分類


talentNo == 0



talentNo != 0

將其計算全域特徵
e.g. 全域點閱 CTR、轉換率 CVR


Search → Browse → Apply
=> 產生 0/1/2 Label



DuckDB & Parquet



- 過量曝光紀錄 (search_log) 導致 Memory OOM
- 進行 Out-of-core GroupBy / Join




Normalization



若信心分數低於門檻，LLM (Qwen) 會介入判斷協助正規化

Query Understanding & Code Mapping

Q: 台北中山跟新北三重明明只隔一條河
但為什麼搜出來距離很近卻被濾掉了？



111 Job Bank

<https://d34x0ef257ul0z.cloudfront.net>

前端系統設計



1111 JobEcho 職地有聲

每次搜尋都能精準回響，讓你每次履歷投遞都「職地有聲」。

● API 已連線

執行版本：20260727T-qwen-kg-v2

關鍵字

後端 資料庫工程師

地區代碼 c0

例 101800

職務代碼 d0

例 140200

🔍 搜尋

推薦職缺

全部選取

取消所有選取

0 筆結果

#8

資料庫工程師

📁 資料庫管理人員 📍 高雄市 # 職缺 ID：130398931

原始輸入文字比對

3 / 4

有出現

✓ 資料

✓ 庫

✓ 工程師

未出現

✗ 後端

根據職缺說明判斷關鍵字

AI 摘要 (生成中)

AI 摘要正在生成；先顯示原文摘錄，完成後會自動替換。

1.資料庫管理與維護(My SQL、SQL Server、Percona)。2.資料庫存取監控及管理。3.資料庫troubleshooting, turing, 分析。4.資料庫備份與還原。

💰 薪資面議

🎓 學歷不拘

📁 經驗不拘



前端系統設計

上傳履歷擷取關鍵字 串接LLM判斷職缺適配度

☆ AI 求職助理

清空對話

×

目前職缺：清潔工 (77002561)

132458379 / 附加條件：「Strong verbal and written communication skills」、132458379 / 英文閱讀：「中等」

履歷.pdf

適配度：資料不足

為何適合：

- {'text': '候選人展現規劃能力，曾設計Wi-Fi CSI數據收集到特徵提取的完整流程，可應用於規劃清潔流程'}
- {'text': '具有處理實際問題的執行力，在Aioters科技公司開發的系統達到90%準確率'}
- {'text': '擁有Python程式設計技能，能協助開發清潔工作流程自動化或資源回收分類系統'}

履歷修改建議：

- {'text': '增加任何環境整理、清潔打掃或志工服務經驗，如參與校園清潔活動或社區環境維護'}
- {'text': '強調執行力與細心特質，將『Achieved up to 90% accuracy』成果連結至對工作品質的重視'}
- {'text': '說明選擇此職缺的動機，如對環境衛生的興趣或願意從基層做起的態度'}

更換履歷

職缺履歷對應分析

例如：這些職缺哪些接受無經驗？

GEN AI Performance & AWS 部署

- 圖譜消融試驗評分
- AWS 部署架構設計



圖譜消融試驗評分

kg-ablation (有圖譜 vs 無圖譜，500 個查詢)：

指標	無圖譜	有圖譜	相對提升
NDCG@10	0.05052	0.05098	+0.92%
Hit@1	0.038	0.040	+5.3%
Hit@10	0.122	0.124	+1.6%
MRR@10	0.0607	0.0629	+3.6%


- top10_changed_rate=0.176 ； improved_query_count=5 、 regressed_query_count=2 、 tie_query_count=493

圖譜消融試驗評分

llm-ablation (LLM 圖譜 vs 規則圖譜，400 個查詢，query_job_labels.parquet test split)：

指標	規則圖譜	LLM 圖譜	相對提升
NDCG@10	0.03801	0.04234	+11.4%
Hit@1	0.025	0.035	+40.0%
Hit@10	0.105	0.1125	+7.1%
MRR@10	0.04755	0.05738	+20.7%

- Bootstrap 95% CI (NDCG@10 delta)： [0.00071, 0.00887]
- improved_query_count=10 、 regressed_query_count=1 、 tie_query_count=389
- 提升集中於 qwen_intervention_test cohort (kg_candidate_changed_rate=0.98 ，即 LLM 正規化確實改變了這批查詢的圖譜候選) ；
general_test cohort (未受 LLM 正規化影響的查詢) delta 為 0，符合預期。



THANK YOU

Q：大圓距離具體用了什麼公式？

分成兩個步驟：

1. 計算緯度與經度的差值
2. 套用 Haversine 公式
3. 加權公式 $1 - (x / 50) \wedge 4$

套用 Haversine 核心公式計算 a ：


$$a = \sin^2\left(\frac{\Delta\phi}{2}\right) + \cos(\phi_1) \cdot \cos(\phi_2) \cdot \sin^2\left(\frac{\Delta\lambda}{2}\right)$$

計算中繼角 c ：

$$c = 2 \cdot \text{atan2}(\sqrt{a}, \sqrt{1-a})$$


計算最終距離 d ：

$$d = R \cdot c$$




城市&職務 Mapping

關鍵字跟系統能理解的城市代碼 c0、職務代碼 d0 對起來
e.g. 台北和新北都屬於台灣，但不該互相匹配到



技術詞保護字典

確保特定技術詞如「C#」「.NET」不會被誤傷



LLM白名單驗證

回傳的實體必須是知識圖譜裡真實存在的，不能捏造技能或職稱，也不能夾帶排名分數

輸入資料摘要

檔案	列數	關鍵欄位	匿名比例 (talentNo=0)
search_log_clean.parquet	88,975,254	talentNo , job_id , job_rank , is_identified_user	~33.5%
browse_clean.parquet	959,428	talentNo , employeeNo , is_identified_user	~55.4%
apply_clean.parquet	225,999	talentNo , empNo	~0%(應徵須登入,無匿名問題)

獨立測試集報告 (LTR vs baseline fusion)

指標	baseline (RRF fusion)	LTR rerank	提升
NDCG@10	0.18548	0.19164	+3.3%
Hit@1	0.12773	0.13879	+8.7%
Hit@10	0.35161	0.36116	+2.7%
MRR@10	0.19520	0.20591	+5.5%


(18,438 個查詢，完整報告：`artifacts/experiments/reports/test_evaluation_report.json`)

輸出 Schema

cleaned/query_job_labels.parquet (單一寬表,pair-level 特徵 + job-level 特徵攤平在同一列)


欄位	型別	說明
talentNo	Int64	求職者 ID(僅 identified user)
job_id	Int64	職缺 ID
min_job_rank	Int64 (nullable)	該 pair 最佳曝光排名
search_count	Int64	該 pair 被曝光幾次
view_count	Int64	該 pair 被瀏覽幾次
apply_count	Int64	該 pair 被應徵幾次
label	Int8	0/1/2
behavior_score	Float32	同 v1 公式
job_total_exposure_count	Int64	job 全域曝光次數(含匿名)
job_total_view_count	Int64	job 全域瀏覽次數(含匿名)
job_total_apply_count	Int64	job 全域應徵次數
job_view_to_apply_rate	Float32	job 全域轉換率
job_search_to_view_rate	Float32	job 全域點閱率
job_avg_exposed_rank	Float32	job 平均曝光排名
query_job_cooccurrence_count	Int64	(ks, job_id) 全域共現次數
user_total_search_count / user_total_view_count / user_total_apply_count	Int64	該使用者一週活躍度
user_company_view_count	Int64	該使用者對同公司職缺的瀏覽次數

Behavior Labels & Ranking




LLM / 規則實體萃取、城市&職務 Mapping

抽出技能、職稱、公司、產業、城市、語言、證照七種實體



實體正規化

若信心分數低於門檻，LLM (Qwen) 會介入判斷協助正規化



Graph 建置

利用 duckDB 和 parquet 離線建置